



**UNIVERSIDAD
MAYOR**
para espíritus emprendedores

UNIVERSIDAD MAYOR
FACULTAD DE CIENCIAS, INGENIERIA Y TECNOLOGIA

**MATENERGY-ML: CRIBADO COMPUTACIONAL DE
MATERIALES PARA CÁTODOS Y ÁNODOS DE BATERÍAS DE
ION-LITIO MEDIANTE INTELIGENCIA ARTIFICIAL**

TRABAJO 2 - INTELIGENCIA ARTIFICIAL

Por

**CAMILO RIQUELME
BENJAMÍN INFANTE**

Profesor: Carlos Muñoz

Santiago, Chile.
Junio, 2026

Contenidos

Tabla de Contenidos	1
Resumen	2
1. Diseño e Implementación del Sistema	3
1.1. Descripción del Problema	3
1.2. Requisitos y Criterios de Diseño	3
1.3. Diseño de la Solución	4
1.3.1. Arquitectura General	4
1.3.2. Selección de Variables y Datos	4
1.3.3. Decisiones de Ingeniería	4
1.4. Implementación	5
1.4.1. Preprocesamiento de Datos	5
1.4.2. Entrenamiento del Modelo	5
1.4.3. Validaciones y Manejo de Errores	5
1.4.4. Módulo de Trabajos DFT (Etapas 13)	6
1.5. Evaluación y Resultados	6
1.5.1. Métricas de Desempeño	6
1.5.2. Análisis de Resultados	6
1.5.3. Limitaciones del Sistema	7
1.6. Conclusiones	7
Bibliografía	8

Resumen

MatEnergy-ML es una plataforma computacional que aplica aprendizaje automático clásico sobre datos de Teoría del Funcional de la Densidad (DFT) para acelerar el cribado de materiales candidatos para cátodos y ánodos de baterías de ion-litio. En lugar de calcular propiedades cuánticas costosas para cada composición candidata, el sistema entrena modelos de regresión (*Ridge Regression*, *Random Forest*, *Gradient Boosting*) y clasificación (*Random Forest*) sobre un conjunto de 151 materiales reales extraídos de Materials Project, prediciendo energía sobre el casco convexo, energía de formación, *band gap* y estabilidad termodinámica binaria a partir de descriptores composicionales calculados con `pymatgen`. La plataforma implementa una arquitectura limpia por capas (FastAPI, PostgreSQL, React), con autenticación JWT, control de acceso basado en roles, verificación de integridad de artefactos mediante SHA-256, y un sistema de *ranking* transparente y no generativo para priorizar candidatos según su relevancia para aplicaciones de almacenamiento de energía. Los resultados muestran que *Gradient Boosting* alcanza un MAE de prueba de 0.0186 eV/átomo para energía sobre el casco convexo, mientras que *Random Forest* predice la energía de formación con $R^2 = 0,869$; el clasificador de estabilidad alcanza F1-macro= 0,583 sobre el conjunto de prueba. Se discuten las limitaciones del tamaño del conjunto de datos y del alcance puramente composicional de los descriptores, así como la diferencia entre estabilidad termodinámica y desempeño electroquímico real de una batería.

Palabras clave: aprendizaje automático, ciencia de materiales computacional, baterías de ion-litio, DFT, cribado de materiales.

Capítulo 1

Diseño e Implementación del Sistema

1.1. Descripción del Problema

El diseño de materiales para baterías de ion-litio enfrenta un cuello de botella combinatorio: solo en óxidos y fosfatos de metales de transición con litio, el espacio de composiciones posibles supera las 500 000 combinaciones, de las cuales solo una fracción mínima ha sido calculada mediante Teoría del Funcional de la Densidad (DFT) (Urban y cols., 2016). Un cálculo DFT individual tarda horas o días (Jain y cols., 2013), por lo que evaluar el espacio de candidatos exhaustivamente es inviable.

El problema concreto: *dado un conjunto de materiales con propiedades DFT ya calculadas para cátodos y ánodos de Li-ion (LiFePO_4 (Padhi y cols., 1997), óxidos Li-Co-Mn-Ni), ¿cómo entrenar modelos de aprendizaje automático que aprendan la relación entre composición química y estabilidad termodinámica, prediciendo en microsegundos para composiciones nuevas sin requerir DFT por candidato?* La estabilidad de un óxido mixto depende de interacciones no lineales entre campo de ligandos, radio iónico y electronegatividad (Behler y Parrinello, 2007); no es un problema de fórmula cerrada, lo que justifica recurrir a ML supervisado entrenado sobre datos DFT reales (Ward y cols., 2016; Meredig y cols., 2014).

1.2. Requisitos y Criterios de Diseño

Funcionales: validación de datasets CSV; generación de descriptores composicionales; entrenamiento/comparación de modelos de regresión y clasificación; predicción por lotes con detección de muestras fuera de dominio (OOD); *ranking* de candidatos por aplicación (cátodo, ánodo, electrolito sólido).

No funcionales: reproducibilidad (semilla fija, *hash* SHA-256 de datasets/artefactos); seguridad (autenticación, RBAC, validación estricta de archivos); trazabilidad (auditoría de

cada predicción); honestidad científica (nunca calibrar una predicción sin justificarlo; advertir predicciones fuera de dominio).

Restricción de seguridad: PyJWT exclusivo para tokens, *hashing* de contraseñas con Argon2, y prohibición de ejecutar contenido subido por el usuario.

1.3. Diseño de la Solución

1.3.1. Arquitectura General

Arquitectura limpia por capas: el dominio no depende de infraestructura, la aplicación solo depende del dominio. Flujo de una predicción: API (FastAPI) → Caso de uso → Servicio de dominio → Repositorio → PostgreSQL / artefacto .joblib. Esto permite probar la lógica científica sin base de datos real y sustituir el motor de ML sin tocar las rutas HTTP.

1.3.2. Selección de Variables y Datos

Los datos provienen de Materials Project (Jain y cols., 2013), calculados con el funcional PBE-GGA (Perdew y cols., 1996). El dataset demo contiene 154 materiales Li-ion (151 válidos tras validación).

Cuadro 1.1: Variables objetivo predichas por el sistema.

Variable	Unidad	Significado físico
energy_above_hull	eV/átomo	Estabilidad relativa al casco convexo
formation_energy_per_atom	eV/átomo	Energía liberada al formarse
band_gap	eV	Carácter conductor/semiconductor/aislante
is_stable	booleano	$EAH \leq 0,05$ eV/átomo

Cada fórmula se transforma en ~ 57 descriptores composicionales vía `pymatgen` (esquema Magpie (Ward y cols., 2016), análogo a `matminer` (Ward y cols., 2018)): estadísticos de propiedades elementales ponderados por fracción atómica, más fracciones de elementos relevantes para baterías (Li, Fe, Mn, Co, Ni, O, P, S).

1.3.3. Decisiones de Ingeniería

Se eligió `scikit-learn` sobre redes de grafos (CGCNN (Xie y Grossman, 2018), MEGNet (Chen y cols., 2019)) porque éstas requieren estructura cristalina 3D no disponible para composiciones hipotéticas, y datasets mucho mayores a 151 materiales (limitación discutida en 1.5.3). Se comparan cuatro modelos —*Ridge*, *Random Forest*, *Gradient Boosting* y un

clasificador *Random Forest*— siguiendo la metodología de *benchmarking* de [Dunn y cols. \(2020\)](#), en vez de comprometerse con uno solo. Toda predicción no calibrada se marca como tal (`is_calibrated=False`).

1.4. Implementación

1.4.1. Preprocesamiento de Datos

Cada CSV se valida antes de tocar la base de datos: codificación UTF-8, tamaño máximo, columna `formula`, rango físico por propiedad, y *hash* SHA-256 para duplicados. Las filas rechazadas se registran con su motivo, nunca se descartan en silencio. Las fórmulas se parsean con `pymatgen.Composition`; una fórmula inválida se rechaza antes del pipeline de descriptores.

1.4.2. Entrenamiento del Modelo

El entrenamiento envuelve el estimador en un *pipeline* con imputación de medianas y escalado robusto, con semilla fija (`FIXED_RANDOM_SEED=42`) para reproducibilidad bit-a-bit:

```
1 def train(self, model_type, task_type, X_train, y_train,
2           hyperparams=None, scale=True):
3     # Merge model-specific defaults with caller overrides
4     defaults = (REGRESSOR_DEFAULTS if task_type == TaskType.REGRESSION
5                 else CLASSIFIER_DEFAULTS).get(model_type, {})
6     params = {**defaults, **(hyperparams or {})}
7     estimator = _build_estimator(model_type, task_type, params)
8     preprocessor = build_sklearn_pipeline(task_type.value, scale=scale)
9
10    # Imputer + scaler + estimator as a single fitted object
11    full_pipeline = Pipeline([("preprocessor", preprocessor),
12                              ("model", estimator)])
13    full_pipeline.fit(X_train, y_train)
14    return full_pipeline
```

Listing 1.1: Pipeline de entrenamiento (adaptado de `infrastructure/ml/trainers.py`)

1.4.3. Validaciones y Manejo de Errores

Todo artefacto `.joblib` se verifica por *hash* SHA-256 antes de cargarse en memoria (`load_artifact`), evitando ejecutar un artefacto alterado; un *hash* no coincidente lanza

`ArtifactIntegrityError` sin cargar el archivo. El sistema define además una jerarquía de excepciones tipadas (`InvalidChemicalFormulaError`, `InsufficientDataError`, `TargetLeakageError`) que separan el mensaje seguro mostrado al usuario del detalle técnico registrado solo en los *logs* del servidor, evitando filtrar trazas internas.

1.4.4. Módulo de Trabajos DFT (Etapa 13)

La plataforma incluye además un módulo operativo de orquestación de cálculos DFT (`/api/v1/dft-jobs`: envío, listado, estado, cancelación, ingesta de resultados y descarga de *inputs*), con seguimiento de cada trabajo en PostgreSQL y una página dedicada en el *frontend* (*Trabajos DFT*). Un adaptador local ejecuta cálculos reales vía ASE/EMT para sistemas metálicos (Al, Cu, Ag, Au, Ni, Pd, Pt, Zn, Cd, Hg) y recurre a una aproximación determinista —marcada explícitamente como no equivalente a DFT real— para el resto; un adaptador SLURM genera archivos VASP (POSCAR/INCAR/KPOINTS vía `pymatgen`) y *scripts sbatch* reales, sin conexión aún a un clúster HPC. Esta capa está disponible en la plataforma, pero los resultados de la sección siguiente provienen exclusivamente de datos DFT precalculados de Materials Project, no de cálculos ejecutados por este módulo.

1.5. Evaluación y Resultados

1.5.1. Métricas de Desempeño

Cuadro 1.2: Desempeño real de los modelos activos sobre el conjunto de prueba (151 materiales, *split* 80/20, semilla fija).

Objetivo / Modelo	Métrica de prueba	Valor
EAH (Gradient Boosting)	MAE / RMSE / R^2	0.0186 / 0.0293 eV/at. / 0.155
E_f por átomo (Random Forest)	MAE / RMSE / R^2	0.210 / 0.301 eV/at. / 0.869
<code>is_stable</code> (RF, clasificación)	F1-macro / ROC-AUC	0.583 / 0.692

1.5.2. Análisis de Resultados

La energía de formación se predice con alta precisión ($R^2 = 0,869$), consistente con [Meredig y cols. \(2014\)](#). `energy_above_hull` —la propiedad de estabilidad más relevante para ciclado— es más difícil ($R^2 = 0,155$): es relativa al casco convexo completo del sistema químico, no una propiedad intrínseca, y con 151 muestras el modelo generaliza pobremente entre familias químicas. El clasificador binario (F1-macro= 0,583) es más robusto que la regresión continua equivalente al colapsar el problema a una decisión binaria con `class_weight="balanced"`.

La validación cruzada ($\text{MAE}_{cv} = 0,0166$) confirma que estas cifras son estables, no producto de un *split* afortunado.

1.5.3. Limitaciones del Sistema

(1) **Tamaño del dataset:** 151 materiales es insuficiente para generalizar fuera de las familias observadas (Li-Fe-O, Li-Mn-O, Li-Co-O); el sistema marca estas predicciones como OOD en vez de reportarlas con falsa confianza. (2) **Descriptores composicionales:** dos polimorfos de la misma fórmula (p.ej. TiO_2 rutilo vs. anatasa) son indistinguibles sin información estructural 3D —lo que CGCNN (Xie y Grossman, 2018) resuelve a costa de requerir estructura conocida. (3) **Brecha estabilidad–desempeño:** el sistema predice si un material *existe y es estable* (precondición necesaria), no su voltaje, capacidad específica o conductividad iónica (Urban y cols., 2016; Bachman y cols., 2016), que requieren simulaciones adicionales no incluidas en el dataset. Además, los datos heredan el error sistemático del funcional PBE (Perdew y cols., 1996), y $\text{EAH} = 0$ no garantiza sintetizabilidad experimental (Sun y cols., 2016; Aykol y cols., 2018).

1.6. Conclusiones

El sistema demuestra que un *pipeline* clásico de ML —sin redes generativas ni de grafos— sustituye un cálculo DFT (microsegundos vs. horas) para cribar estabilidad termodinámica de candidatos a cátodos y ánodos de ion-litio, cumpliendo el objetivo de reducir el costo de explorar el espacio composicional. El desempeño —alto para energía de formación, moderado para estabilidad— es honesto dado el tamaño del dataset, y se comunica explícitamente en vez de ocultarse. La Etapa 13 —el módulo de orquestación de trabajos DFT descrito en Implementación— ya está operativa; el trabajo futuro es conectarla a un clúster HPC real, incorporar sus resultados al dataset de entrenamiento, y sumar descriptores estructurales o redes de grafos cristalinos (CGCNN, ALIGNN) cuando exista información 3D suficiente, cerrando progresivamente la brecha hacia la predicción directa de desempeño de batería y no solo de estabilidad termodinámica.

Bibliografía

- Aykol, M., Dwaraknath, S. S., Sun, W., y Persson, K. A. (2018). Thermodynamic limit for synthesis of metastable inorganic materials. *Science Advances*, 4(4), eaaq0148. Descargado de <https://doi.org/10.1126/sciadv.aaq0148> doi: 10.1126/sciadv.aaq0148
- Bachman, J. C., Muy, S., Grimaud, A., Chang, H.-H., Pour, N., Lux, S. F., ... Shao-Horn, Y. (2016). Inorganic solid-state electrolytes for lithium batteries: Mechanisms and properties governing ion conduction. *Chemical Reviews*, 116(1), 140–162. Descargado de <https://doi.org/10.1021/acs.chemrev.5b00563> doi: 10.1021/acs.chemrev.5b00563
- Behler, J., y Parrinello, M. (2007). Generalized neural-network representation of high-dimensional potential-energy surfaces. *Physical Review Letters*, 98(14), 146401. Descargado de <https://doi.org/10.1103/PhysRevLett.98.146401> doi: 10.1103/PhysRevLett.98.146401
- Chen, C., Ye, W., Zuo, Y., Zheng, C., y Ong, S. P. (2019). Graph networks as a universal machine learning framework for molecules and crystals. *Chemistry of Materials*, 31(9), 3564–3572. Descargado de <https://doi.org/10.1021/acs.chemmater.9b01294> doi: 10.1021/acs.chemmater.9b01294
- Dunn, A., Wang, Q., Ganose, A., Dopp, D., y Jain, A. (2020). Benchmarking materials property prediction methods: The matbench test set and automatminer reference algorithm. *npj Computational Materials*, 6(1), 138. Descargado de <https://doi.org/10.1038/s41524-020-00406-3> doi: 10.1038/s41524-020-00406-3
- Jain, A., Ong, S. P., Hautier, G., Chen, W., Richards, W. D., Dacek, S., ... Persson, K. A. (2013). Commentary: The materials project: A materials genome approach to accelerating materials innovation. *APL Materials*, 1(1), 011002. Descargado de <https://doi.org/10.1063/1.4812323> doi: 10.1063/1.4812323
- Meredig, B., Agrawal, A., Kirklin, S., Saal, J. E., Doak, J. W., Thompson, A., ... Wolverton, C. (2014). Combinatorial screening for new materials in unconstrained composition space

Bibliografía

- with machine learning. *Physical Review B*, 89(9), 094104. Descargado de <https://doi.org/10.1103/PhysRevB.89.094104> doi: 10.1103/PhysRevB.89.094104
- Padhi, A. K., Nanjundaswamy, K. S., y Goodenough, J. B. (1997). Phospho-olivines as positive-electrode materials for rechargeable lithium batteries. *Journal of The Electrochemical Society*, 144(4), 1188–1194. Descargado de <https://doi.org/10.1149/1.1837571> doi: 10.1149/1.1837571
- Perdew, J. P., Burke, K., y Ernzerhof, M. (1996). Generalized gradient approximation made simple. *Physical Review Letters*, 77(18), 3865–3868. Descargado de <https://doi.org/10.1103/PhysRevLett.77.3865> doi: 10.1103/PhysRevLett.77.3865
- Sun, W., Dacek, S. T., Ong, S. P., Hautier, G., Jain, A., Richards, W. D., . . . Ceder, G. (2016). The thermodynamic scale of inorganic crystalline metastability. *Science Advances*, 2(11), e1600225. Descargado de <https://doi.org/10.1126/sciadv.1600225> doi: 10.1126/sciadv.1600225
- Urban, A., Seo, D.-H., y Ceder, G. (2016). Computational understanding of li-ion batteries. *npj Computational Materials*, 2(1), 16002. Descargado de <https://doi.org/10.1038/npjcompumats.2016.2> doi: 10.1038/npjcompumats.2016.2
- Ward, L., Agrawal, A., Choudhary, A., y Wolverton, C. (2016). A general-purpose machine learning framework for predicting properties of inorganic materials. *npj Computational Materials*, 2(1), 16028. Descargado de <https://doi.org/10.1038/npjcompumats.2016.28> doi: 10.1038/npjcompumats.2016.28
- Ward, L., Dunn, A., Faghaninia, A., Zimmermann, N. E. R., Bajaj, S., Wang, Q., . . . Jain, A. (2018). Matminer: An open source toolkit for materials data mining. *Computational Materials Science*, 152, 60–69. Descargado de <https://doi.org/10.1016/j.commatsci.2018.05.018> doi: 10.1016/j.commatsci.2018.05.018
- Xie, T., y Grossman, J. C. (2018). Crystal graph convolutional neural networks for an accurate and interpretable prediction of material properties. *Physical Review Letters*, 120(14), 145301. Descargado de <https://doi.org/10.1103/PhysRevLett.120.145301> doi: 10.1103/PhysRevLett.120.145301